Inteligență Artificială - Tema 2

Utilizarea modelelor neurale pentru clasificarea imaginilor

Raport de rezultate și interpretare

Autor: Florea Delia-Cristina
Grupa: 333CC

1. Introducere și descrierea datelor

Setul „Vai de pielea mea” conține imagini dermatoscopice RGB cu 7 clase de diagnostic. Setul „You’re on candid camera” conține imagini RGB de expresii faciale, tot cu 7 clase. Ambele seturi sunt dezechilibrate, motiv pentru care metricile principale urmărite au fost F1-macro, F1-micro și accuracy, nu doar acuratețea globală.

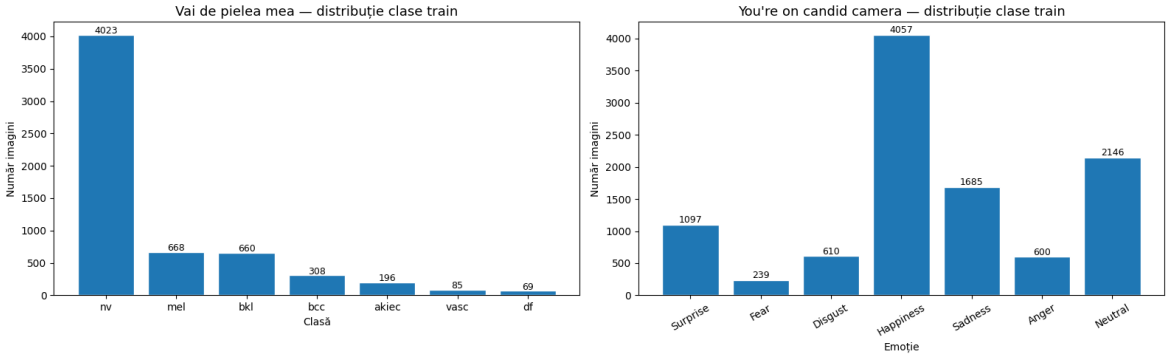


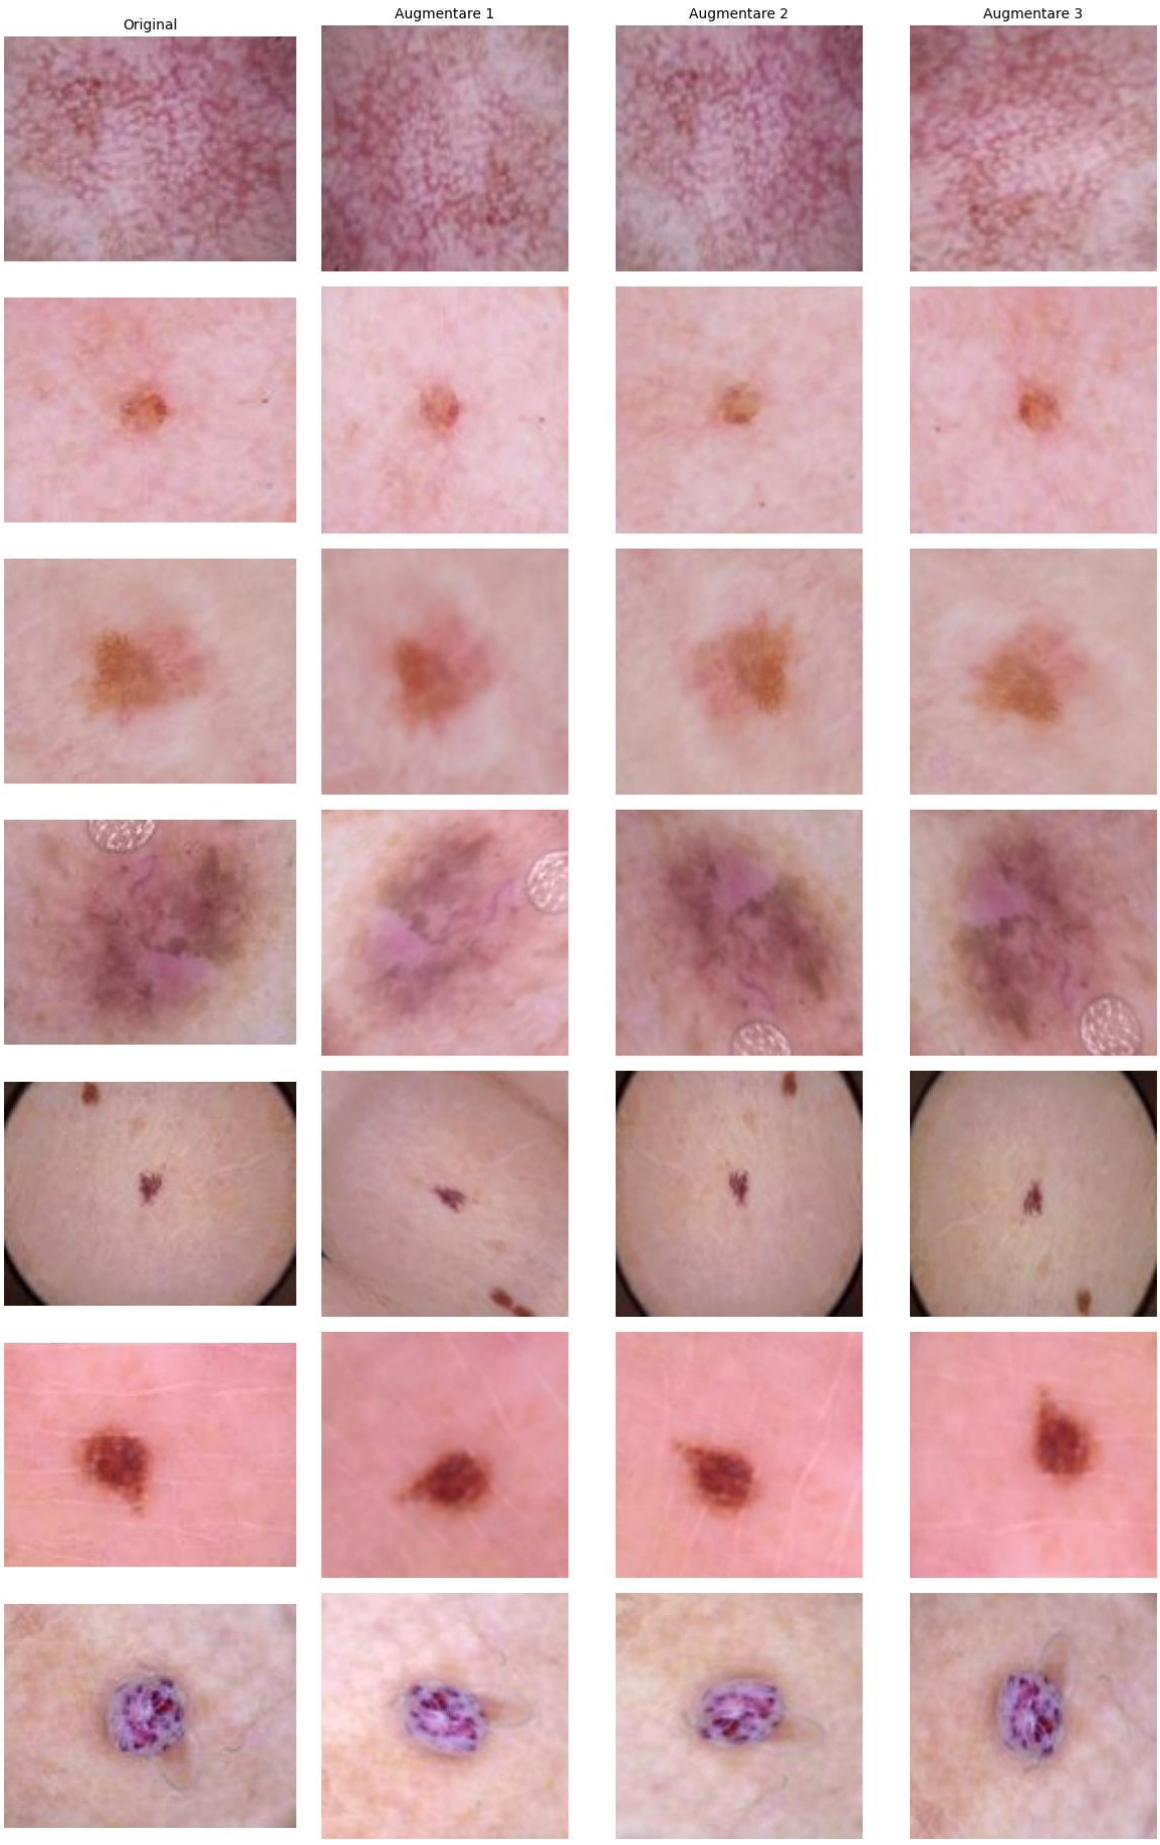
Figura 1. Distribuția claselor în seturile de antrenare.

2. Pipeline de preprocesare și augmentare

Imaginile au fost încărcate prin clase Dataset personalizate și au fost transformate în tensori PyTorch. Pentru modelele simple s-au folosit redimensionări apropiate de rezoluția originală, iar pentru fine-tuning s-au folosit dimensiuni compatibile cu modele preantrenate pe ImageNet, de exemplu 224x224 sau 260x260. Normalizarea a fost realizată cu statisticile datasetului sau cu statisticile ImageNet pentru modelele preantrenate.

Augmentările au fost aplicate doar pe setul de antrenare. Pentru skin au fost folosite flip-uri, rotații și modificări moderate de culoare, deoarece leziunile nu au o orientare semantică fixă. Pentru camera s-au folosit augmentări mai prudente: flip orizontal, rotații mici, crop-uri și ColorJitter moderat; nu s-au folosit flip-uri verticale, deoarece acestea ar schimba semantica unei fețe.

3.1 Augmentări — Vai de pielea mea



3.1 Augmentări — You're on candid camera



3. Arhitectura MLP

Arhitectura MLP a fost folosită ca model de bază pentru ambele seturi de date. Imaginile au fost redimensionate, normalizate și apoi aplatizate într-un vector. Modelul a inclus straturi liniare, funcții ReLU și, pentru varianta regularizată, dropout. Scopul ablației a fost să se observe impactul dropout-ului asupra generalizării.

Tabel 1. Ablație MLP cu/fără dropout

Dataset	Variantă MLP	F1-macro local
Skin	cu dropout	0.34057
Skin	fără dropout	0.36523
Camera	cu dropout	0.32364
Camera	fără dropout	0.40897

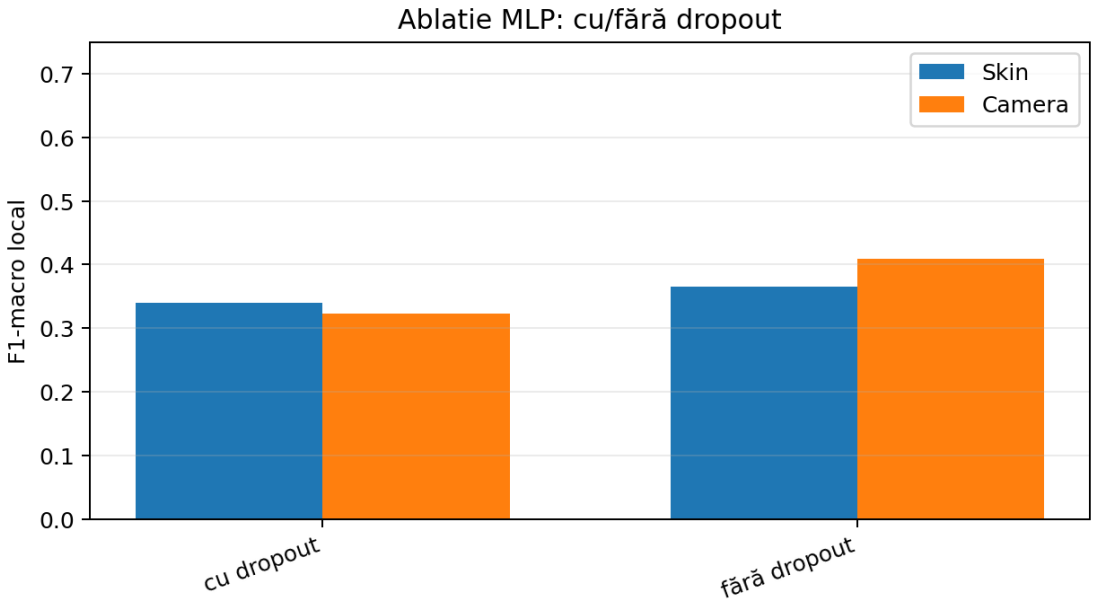


Figura 4. Compararea variantelor MLP cu/fără dropout.

Tabel 2. Metrici locale MLP după mini-antrenare

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	MLP după fine-tuning scurt	0.72391	0.33153	0.72391
You're on candid camera	MLP după fine-tuning scurt	0.58084	0.35244	0.58084

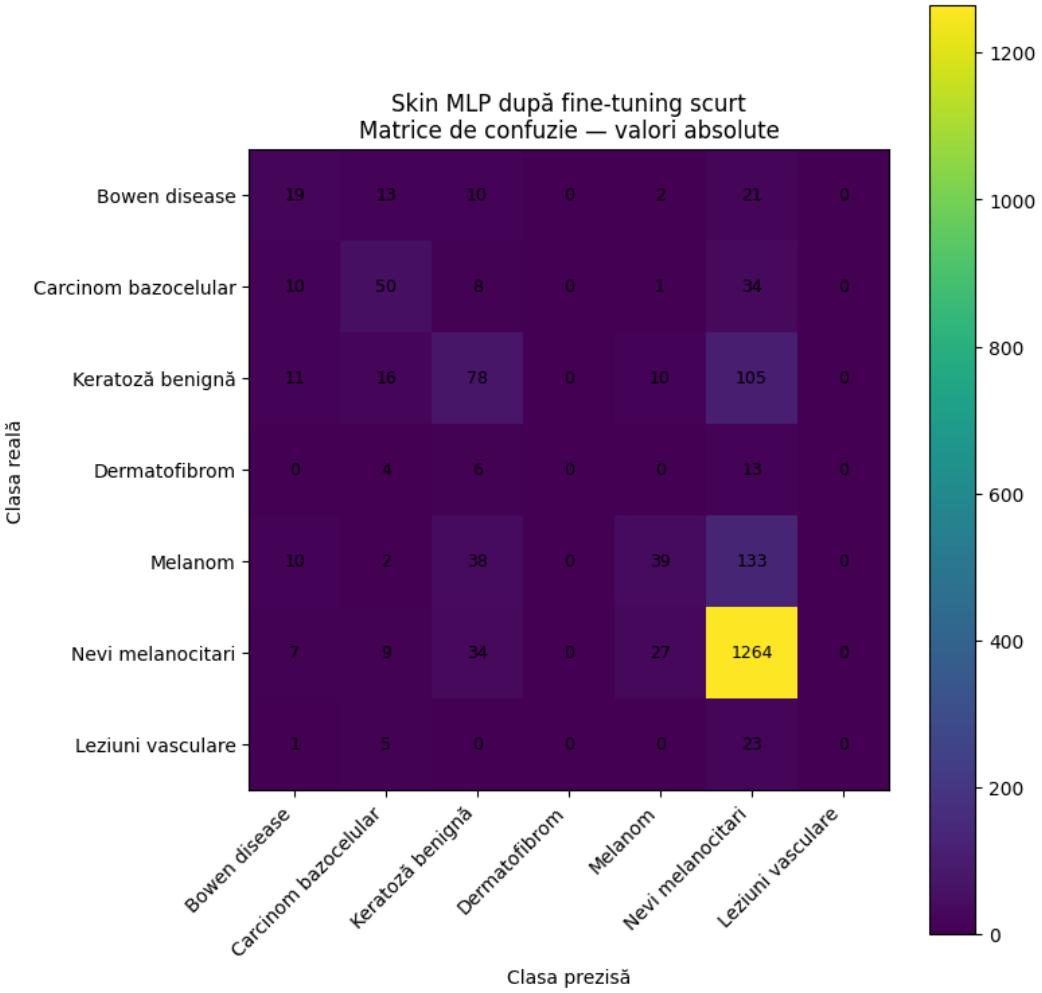


Figura 5. Matrice de confuzie - Skin MLP după fine-tuning scurt.

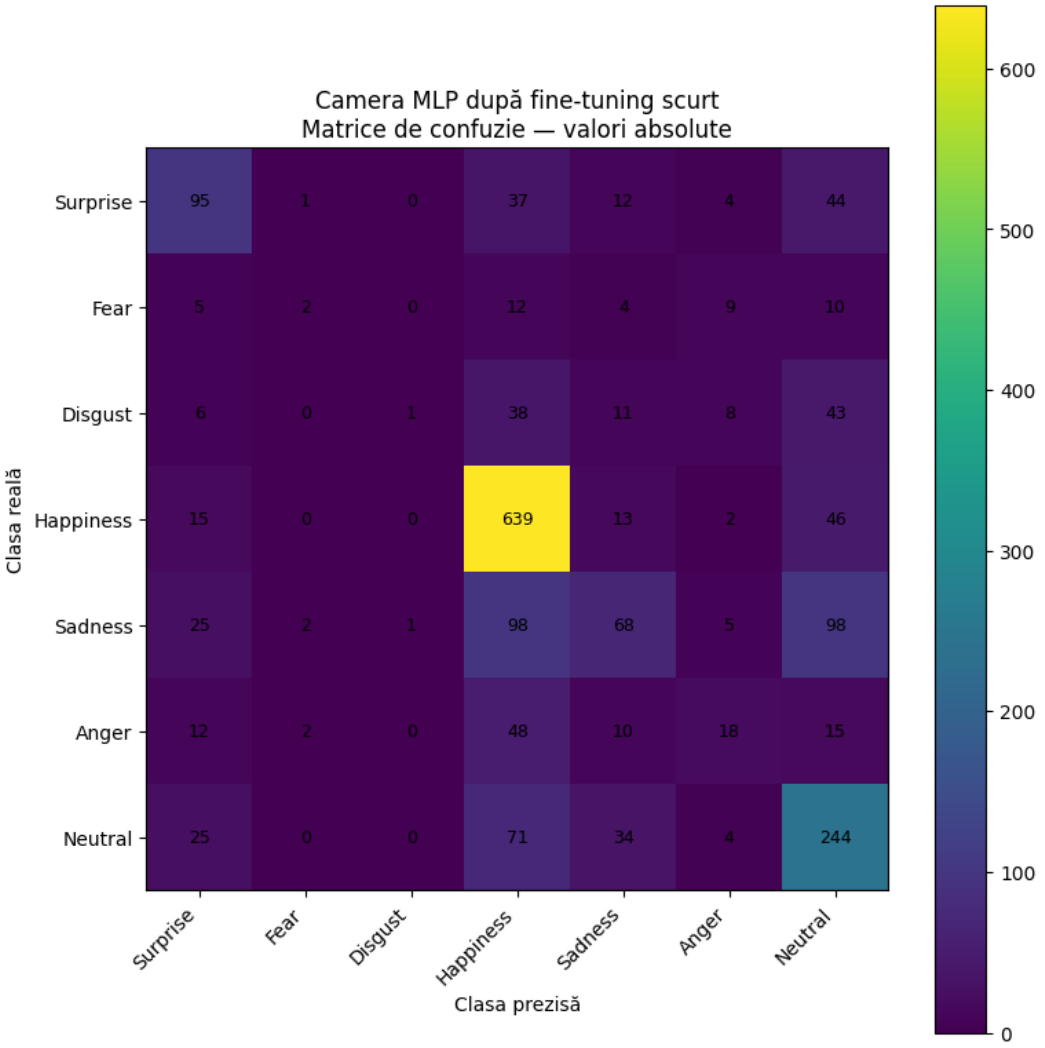


Figura 6. Matrice de confuzie - Camera MLP după fine-tuning scurt.

Interpretare: pe setul skin, MLP-ul atinge o acuratețe rezonabilă datorită dominanței clasei majoritare, însă F1-macro rămâne mai scăzut, ceea ce arată dificultatea pe clasele rare. Pe setul camera, MLP-ul este depășit de modelele convoluționale/fine-tunate, dar oferă un baseline util pentru comparație.

4. Arhitectura CNN

CNN-ul implementat este comun celor două seturi de date și respectă restricțiile cerinței: cel mult 4 straturi convoluționale și cel mult 2 straturi complet conectate. Pentru imagini faciale s-a folosit kernel 3x3 în primul strat, iar pentru skin s-a folosit kernel mai mare sau receptive field mai amplu, deoarece structurile dermatoscopice relevante pot fi mai mari.

Modelul CNN folosește blocuri de tip Convolution - BatchNorm - ReLU - Pooling și global average pooling spre final. În ablații s-a testat impactul BatchNorm, al tipurilor de augmentări și al balansării claselor prin WeightedRandomSampler.

Tabel 3. Ablație CNN cu/fără BatchNorm

Dataset	Variantă CNN	F1-macro local
Skin	cu BatchNorm	0.27056
Skin	fără BatchNorm	0.11458
Camera	cu BatchNorm	0.16361

Camera	fără BatchNorm	0.11500

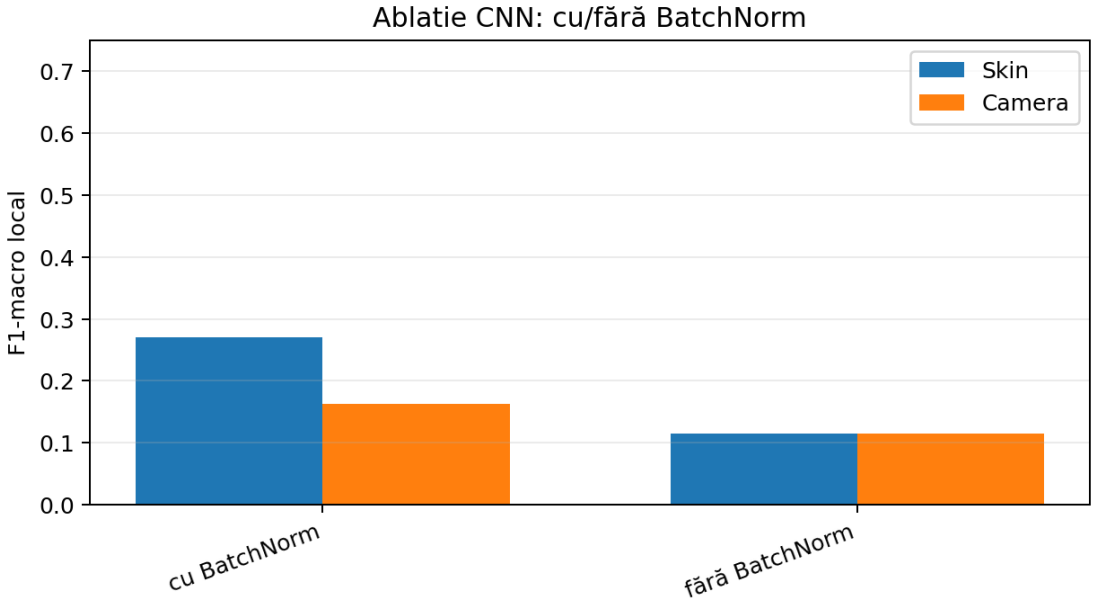


Figura 7. Impactul BatchNorm în CNN.

Tabel 4. Ablație CNN pe tipuri de augmentare

Dataset	Configurație augmentare	F1-macro local
Skin	fără augmentări	0.26145
Skin	augmentări color	0.19933
Skin	toate augmentările	0.16000
Camera	fără augmentări	0.23559
Camera	geometrice	0.18653
Camera	color	0.17566
Camera	toate augmentările	0.15272

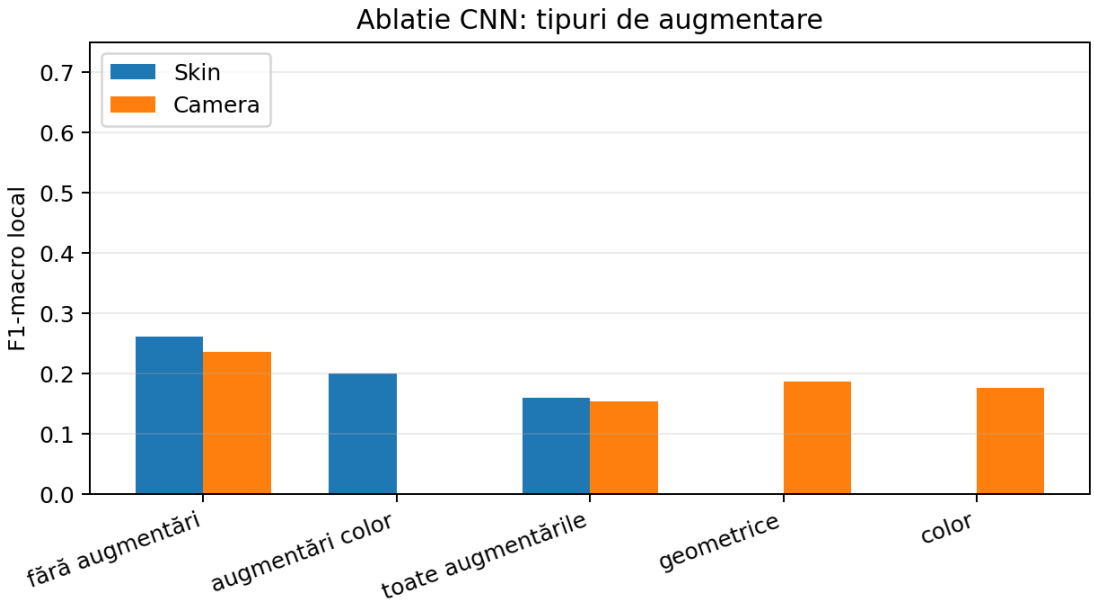


Figura 8. Impactul tipurilor de augmentare asupra F1-macro.

Tabel 5. Ablație pentru tratarea dezechilibrului de clase

Dataset	Configurație	F1-macro local
Skin	CNN baseline cu BatchNorm	0.27056
Skin	CNN cu WeightedRandomSampler	0.37544
Camera	CNN baseline cu BatchNorm	0.16361
Camera	CNN cu WeightedRandomSampler	0.28272

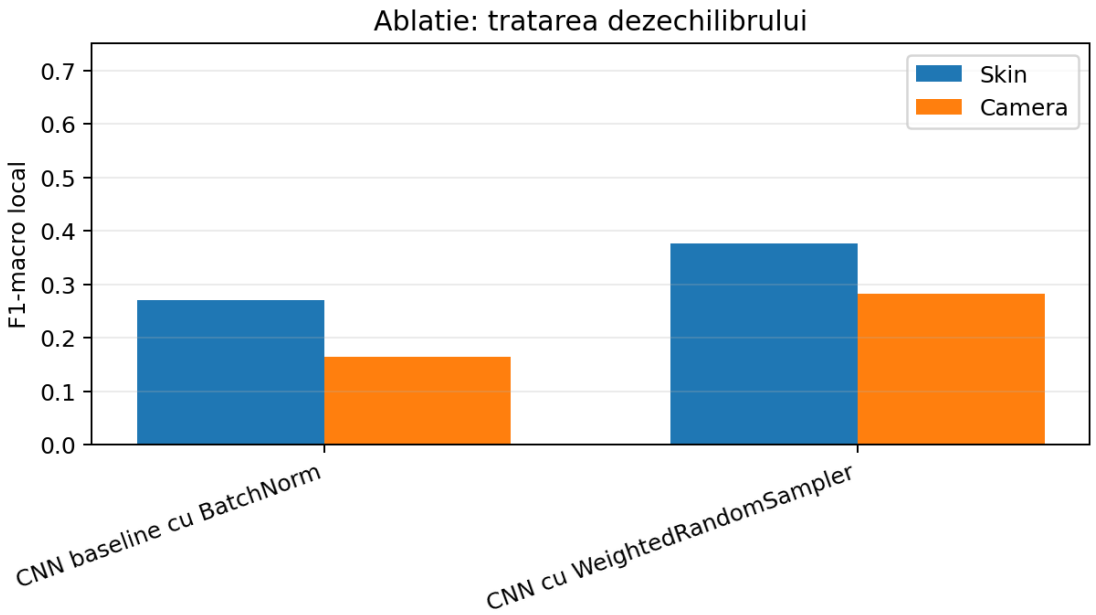


Figura 9. Efectul WeightedRandomSampler asupra F1-macro.

Tabel 6. Metrici locale CNN după mini-antrenare

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	CNN după fine-tuning scurt	0.71143	0.26543	0.71143
You're on candid camera	CNN după fine-tuning scurt	0.49374	0.25623	0.49374

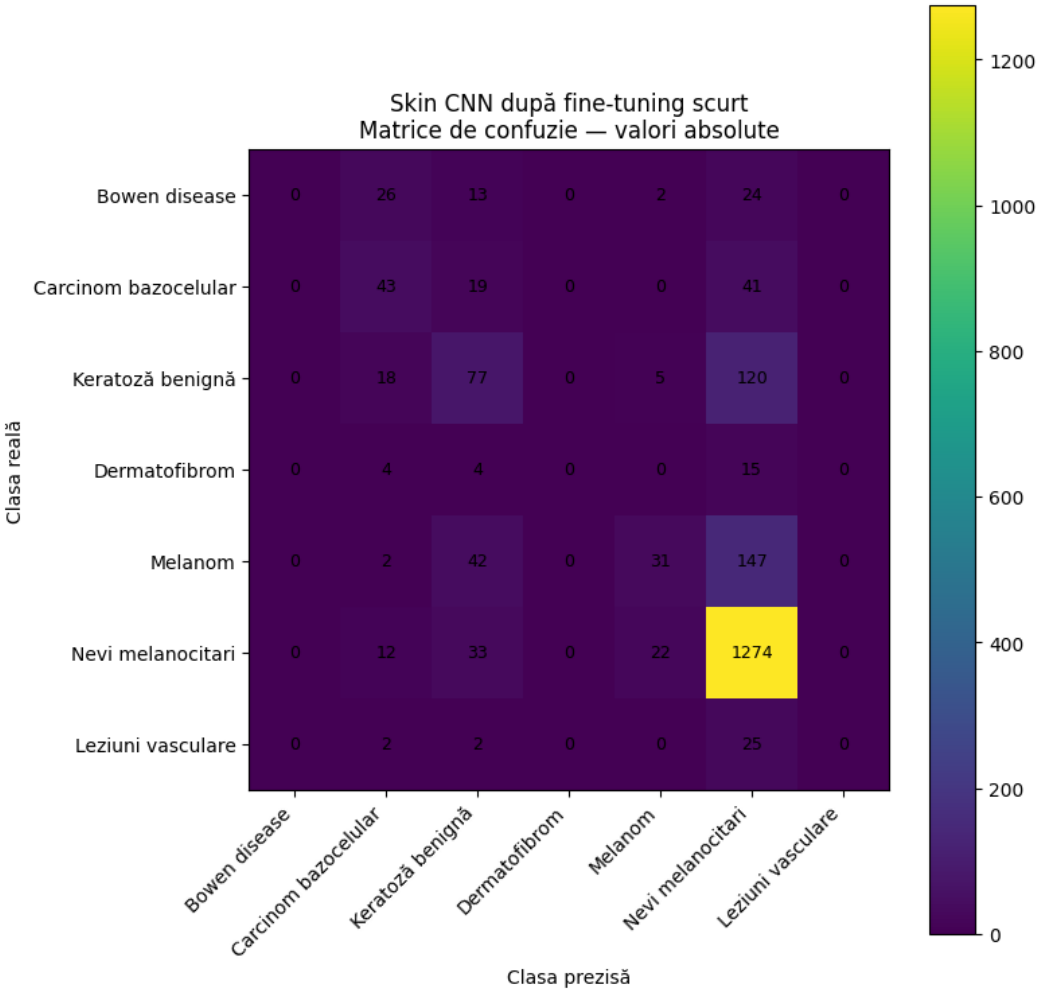


Figura 10. Matrice de confuzie - Skin CNN după fine-tuning scurt.

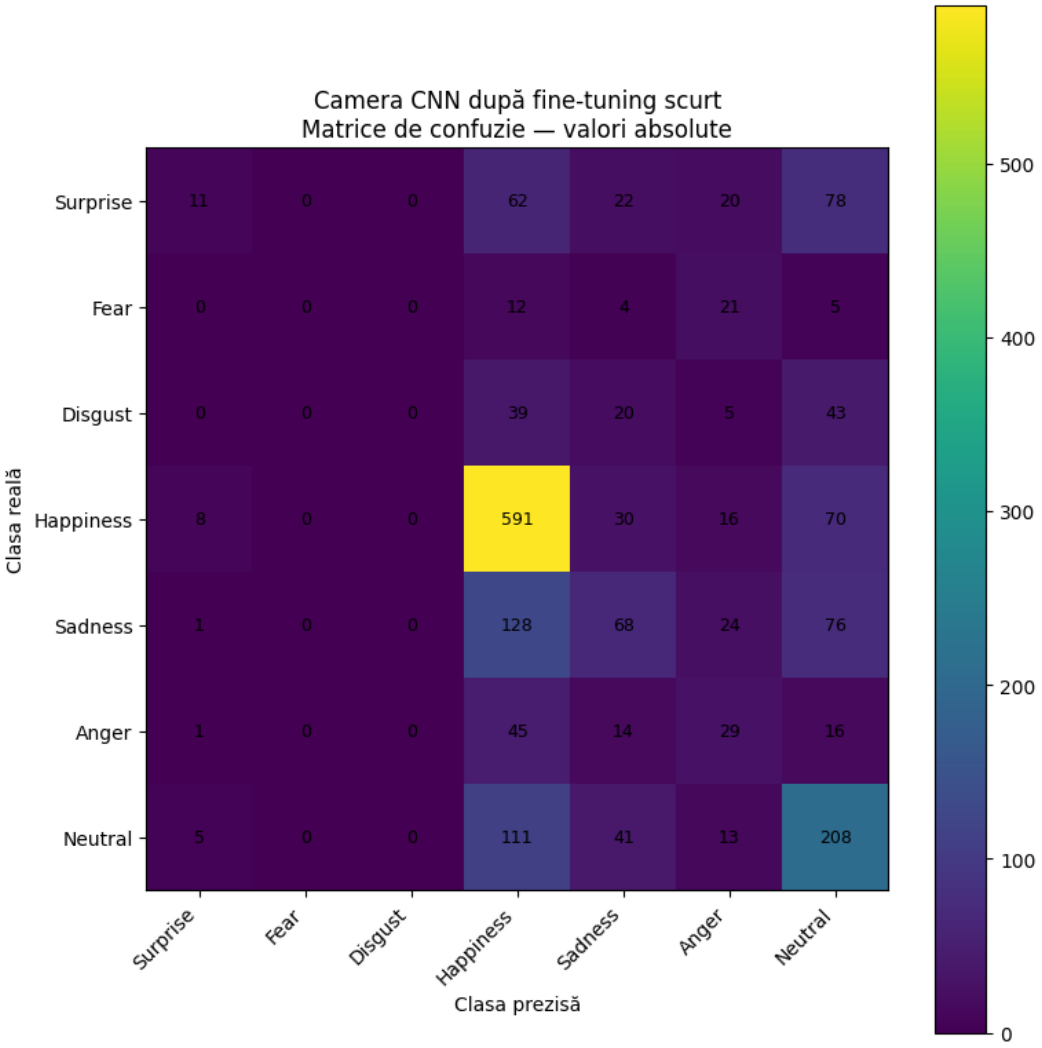


Figura 11. Matrice de confuzie - Camera CNN după fine-tuning scurt.

Interpretare: BatchNorm stabilizează antrenarea, mai ales pentru skin. Pentru camera, rezultatele CNN-ului simplu rămân modeste, ceea ce sugerează că variația de iluminare, expresie și ocluzie necesită modele preantrenate sau fine-tuning mai puternic.

5. Fine-tuning și modele finale

Pentru fine-tuning au fost folosite modele preantrenate pe ImageNet, în special MobileNetV2, ResNet18 și ulterior variante mai puternice/eficiente. Capul de clasificare a fost înlocuit cu un strat adaptat celor 7 clase. În unele experimente backbone-ul a fost înghețat, iar în altele a fost făcut fine-tuning complet cu rate de învățare diferențiate pentru backbone și head.

Tabel 7. Ablație fine-tuning cu/fără learning rate warmup

Dataset	Configurație fine-tuning	F1-macro local
Skin	MobileNetV2 fără warmup	0.37035
Skin	MobileNetV2 cu warmup	0.32066
Camera	MobileNetV2 fără warmup	0.33974
Camera	MobileNetV2 cu warmup	0.33979

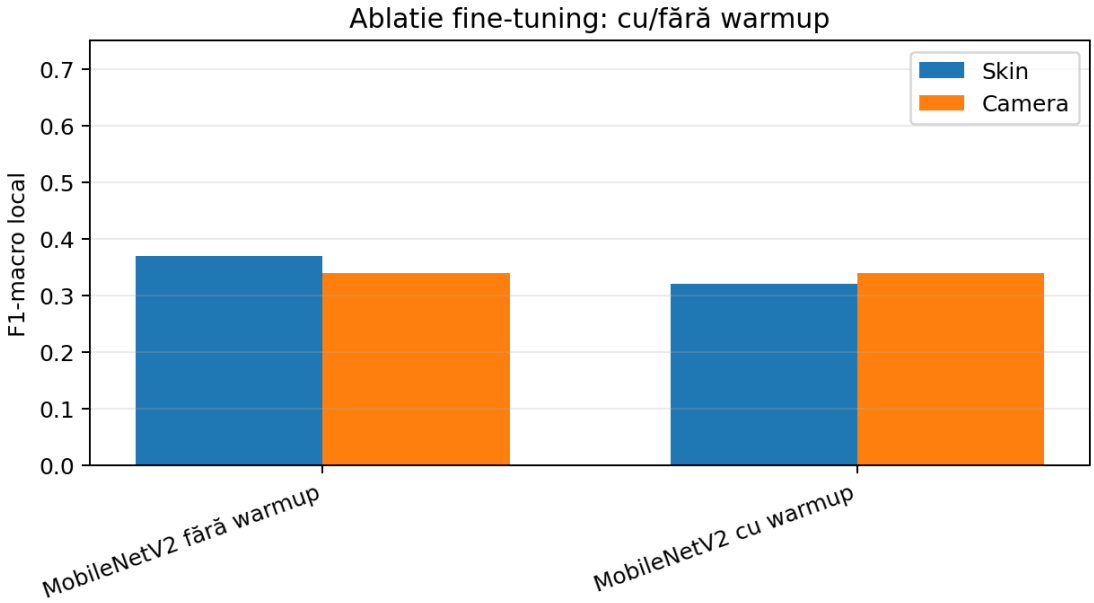


Figura 12. Impactul warmup-ului în fine-tuning.

Tabel 8. Metrici locale pentru modelele finale după mini-antrenare

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	Strong skin model după fine-tuning scurt	0.81378	0.67238	0.81378
You're on candid camera	face_final_model după fine-tuning scurt	0.90038	0.90024	0.90038

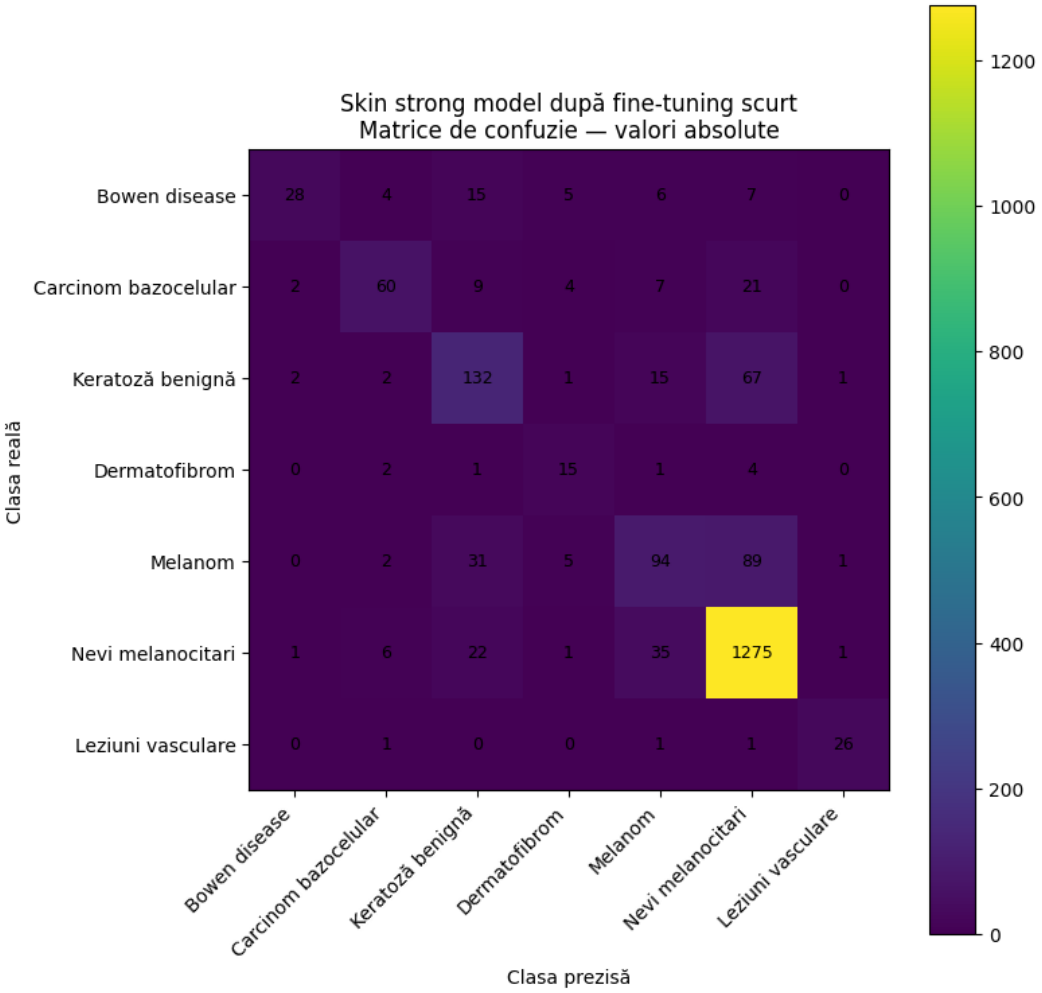


Figura 13. Matrice de confuzie - Strong skin model după fine-tuning scurt.

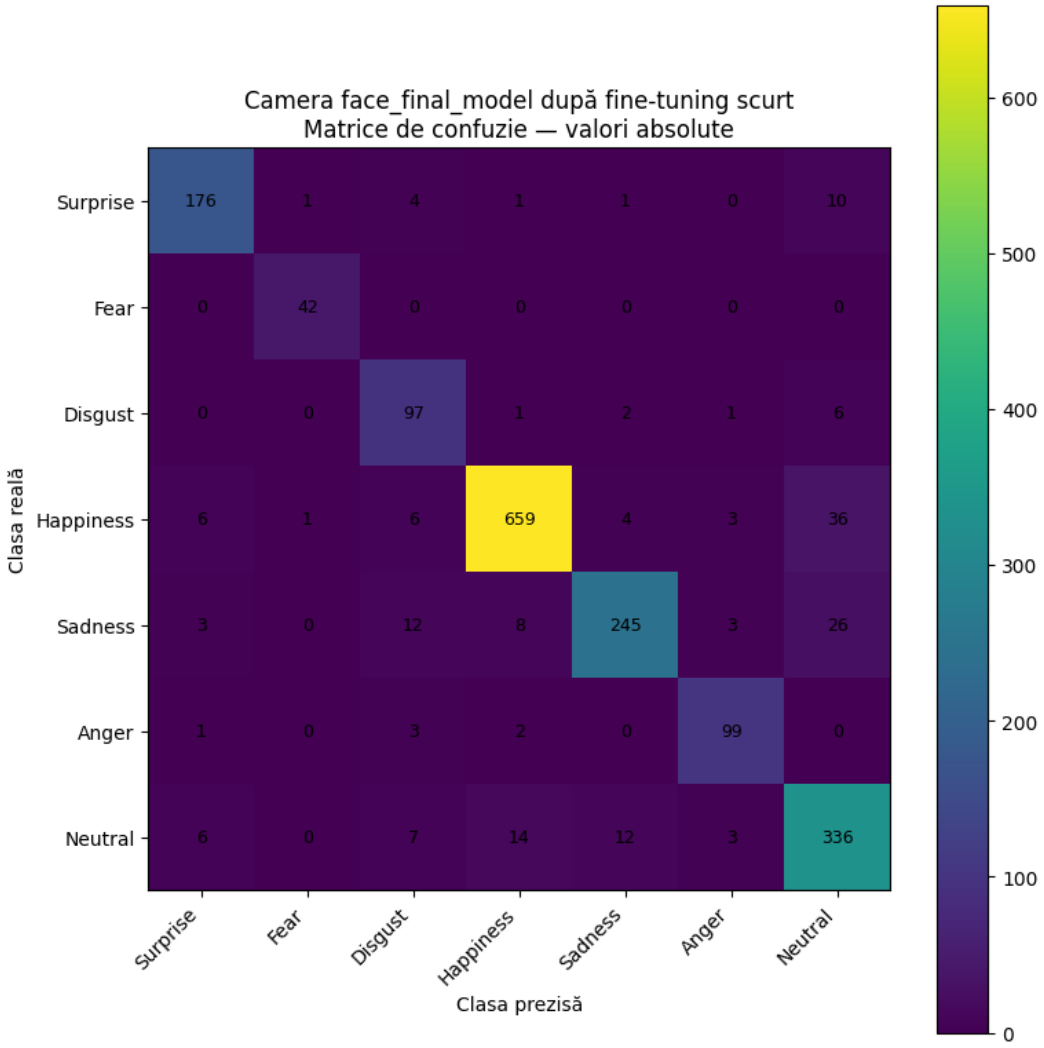


Figura 14. Matrice de confuzie - Camera face_final_model după fine-tuning scurt.

Interpretare: modelul strong pentru skin obține cel mai bun echilibru între clase dintre variantele locale raportate, cu F1-macro 0.67238 după mini-antrenare. Pentru camera, modelul face_final_model atinge F1-macro local 0.90024, semnificativ peste MLP și CNN simple.

6. Ablații și comparații experimentale

Ablațiile au urmărit componentele cerute: dropout în MLP, BatchNorm în CNN, tipurile de augmentare, tratarea dezechilibrului de clase și fine-tuning cu/fără warmup. Rezultatele arată că efectul fiecărei tehnici depinde puternic de dataset. Pe skin, balansarea prin sampler și fine-tuning-ul aduc cele mai vizibile îmbunătățiri. Pe camera, modelele preantrenate și post-procesarea predicțiilor au fost cele mai importante pentru scorul final Kaggle.

Tabel 9. Cele mai bune rezultate locale pe familie de modele

Dataset	Familie	Cea mai bună variantă locală	F1-macro local
Skin	MLP	MLP fără dropout	0.36523
Skin	CNN	CNN cu WeightedRandomSampler	0.37544
Skin	Fine-tuning final	Strong skin model	0.67238
Camera	MLP	MLP fără dropout	0.40897
Camera	CNN	CNN cu WeightedRandomSampler	0.28272
Camera	Fine-tuning final	face_final_model	0.90024

7. Rezultate Kaggle și post-procesare

Scorurile finale au fost evaluate cu F1-macro pe platforma Kaggle. Pentru skin, fișierul folosit a fost submission_mole.csv. Pentru camera, fișierul final a folosit ensemble și post-procesare. Am inclus atât scorurile după mini-antrenarea scurtă, cât și best score-ul obținut anterior, deoarece platforma reține cel mai bun rezultat.

Tabel 10. Scoruri Kaggle finale

Dataset	Fișier încărcat / reprezentativ	Scor Kaggle după mini-antrenare	Best score Kaggle	Prag maxim	Status
Vai de pielea mea	submission_mole.csv	0.69927	0.70157	0.67 (ResNet18)	trece
You're on candid camera	camera_quota_submission_after_short.csv	0.77072	0.77673	0.77 (ResNet18)	trece

Tabel 11. Verificarea pragurilor Moodle

Dataset	Cerință	Prag F1-macro	Scor folosit în raport	Status
Vai de pielea mea	MLP	0.20000	0.69927	trece
Vai de pielea mea	CNN	0.40000	0.69927	trece
Vai de pielea mea	Finetuned ResNet18	0.67000	0.69927	trece
Vai de pielea mea	Finetuned MobileNet-v2	0.65000	0.69927	trece
You're on candid camera	MLP	0.19000	0.77072	trece
You're on candid camera	CNN	0.35000	0.77072	trece
You're on candid camera	ResNet18	0.77000	0.77072	trece
You're on candid camera	MobileNetV2	0.76000	0.77072	trece

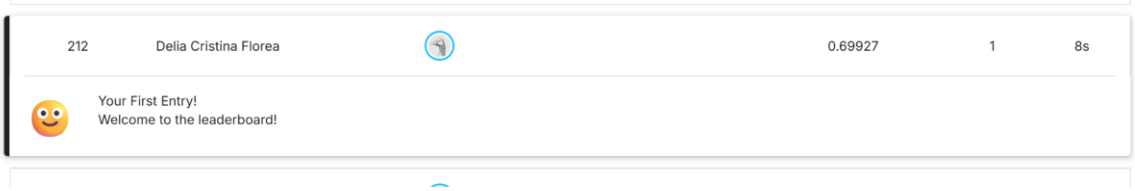


Figura 15. Scor Kaggle pentru „Vai de pielea mea” după mini-antrenare: 0.69927.

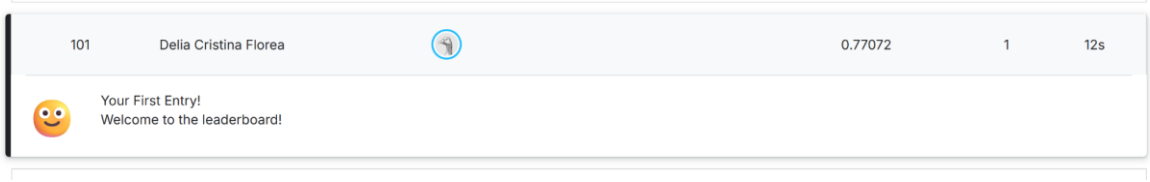


Figura 16. Scor Kaggle pentru „You’re on candid camera” după mini-antrenare: 0.77072.

Pentru „You’re on candid camera”, predicțiile finale au fost obținute printr-un ensemble ponderat al mai multor modele: turbo_model, face_final_model, camera_resnet18_final, camera_mobilenetv2_final și face_model. Probabilitățile produse de aceste modele au fost mediate ponderat, iar ulterior s-a aplicat o post-procesare de tip quota matching.

Quota matching a folosit distribuția de clase publicată în enunț pentru remote_test: 329 Surprise, 74 Fear, 160 Disgust, 1185 Happiness, 478 Sadness, 162 Anger și 680 Neutral. Nu au fost folosite etichetele reale ale imaginilor din remote_test, ci doar distribuția agregată oficială și probabilitățile modelelor. Deoarece remote_test nu conține etichete

reale, nu se poate calcula o matrice de confuzie reală pentru această submisie; matricele de confuzie au fost raportate pe local_test.

8. Matrici de confuzie necesare

În această secțiune sunt centralizate matricile de confuzie necesare pentru PDF. Sunt folosite matricile după mini-antrenarea scurtă, pentru a reflecta valorile finale din notebook. Pentru fiecare dataset sunt incluse MLP, CNN și modelul final/fine-tuning.

Tabel 13. Rezumat metrici pentru matricile de confuzie incluse

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	MLP după fine-tuning scurt	0.72391	0.33153	0.72391
Vai de pielea mea	CNN după fine-tuning scurt	0.71143	0.26543	0.71143
Vai de pielea mea	Strong skin model după fine-tuning scurt	0.81378	0.67238	0.81378
You're on candid camera	MLP după fine-tuning scurt	0.58084	0.35244	0.58084
You're on candid camera	CNN după fine-tuning scurt	0.49374	0.25623	0.49374
You're on candid camera	face_final_model după fine-tuning scurt	0.90038	0.90024	0.90038

Figurile 5-6 conțin matricile MLP, figurile 10-11 conțin matricile CNN, iar figurile 13-14 conțin matricile pentru modelele finale. Variantele normalizate sunt incluse în anexă.

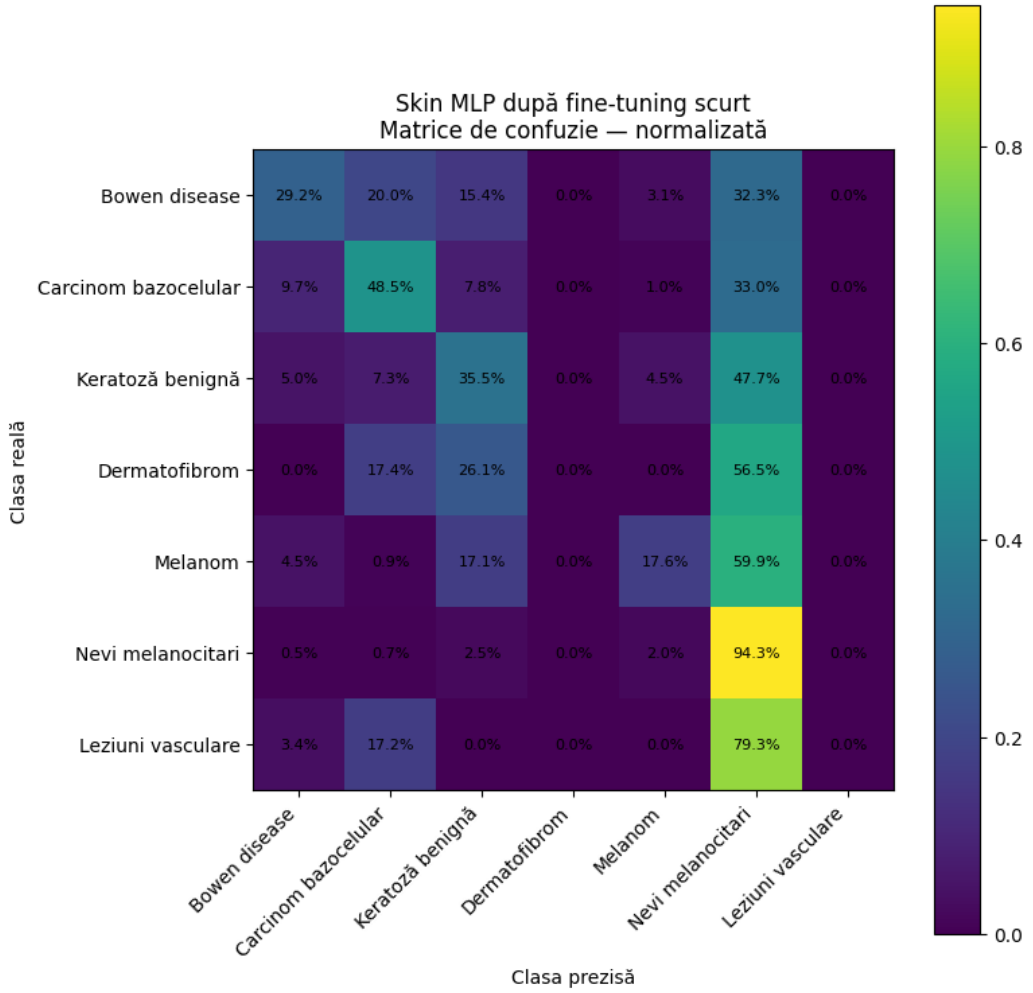
9. Concluzii

Modelele de bază MLP și CNN oferă repere utile, însă nu sunt suficiente pentru performanțe competitive pe ambele seturi de date, mai ales din cauza dezechilibrului de clase și a variabilității imaginilor. CNN-ul beneficiază de BatchNorm și de metode de balansare, dar fine-tuning-ul modelelor preantrenate produce cele mai bune rezultate locale și Kaggle.

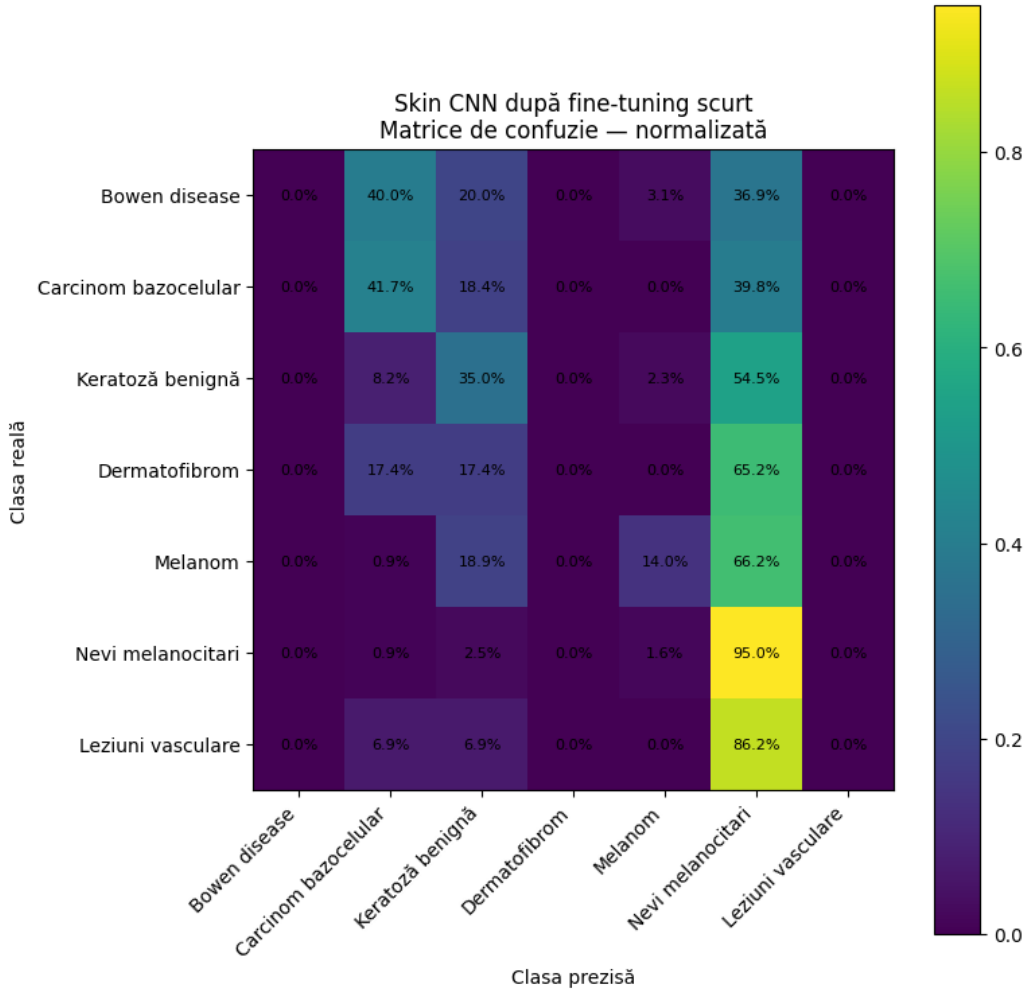
Pentru skin, scorul Kaggle după mini-antrenare a fost 0.69927, iar best score-ul obținut a fost 0.70157, depășind pragul maxim de 0.67. Pentru camera, scorul după mini-antrenare a fost 0.77072, iar best score-ul a fost 0.77673, depășind pragul maxim de 0.77. Fără post-procesarea prin quota matching, scorul camera era 0.75224, ceea ce nu depășea pragul ResNet18. Post-procesarea a fost astfel decisivă pentru trecerea tuturor pragurilor, folosind exclusiv informație publică din enunț și probabilitățile modelelor.

Anexă: matrici de confuzie normalizate

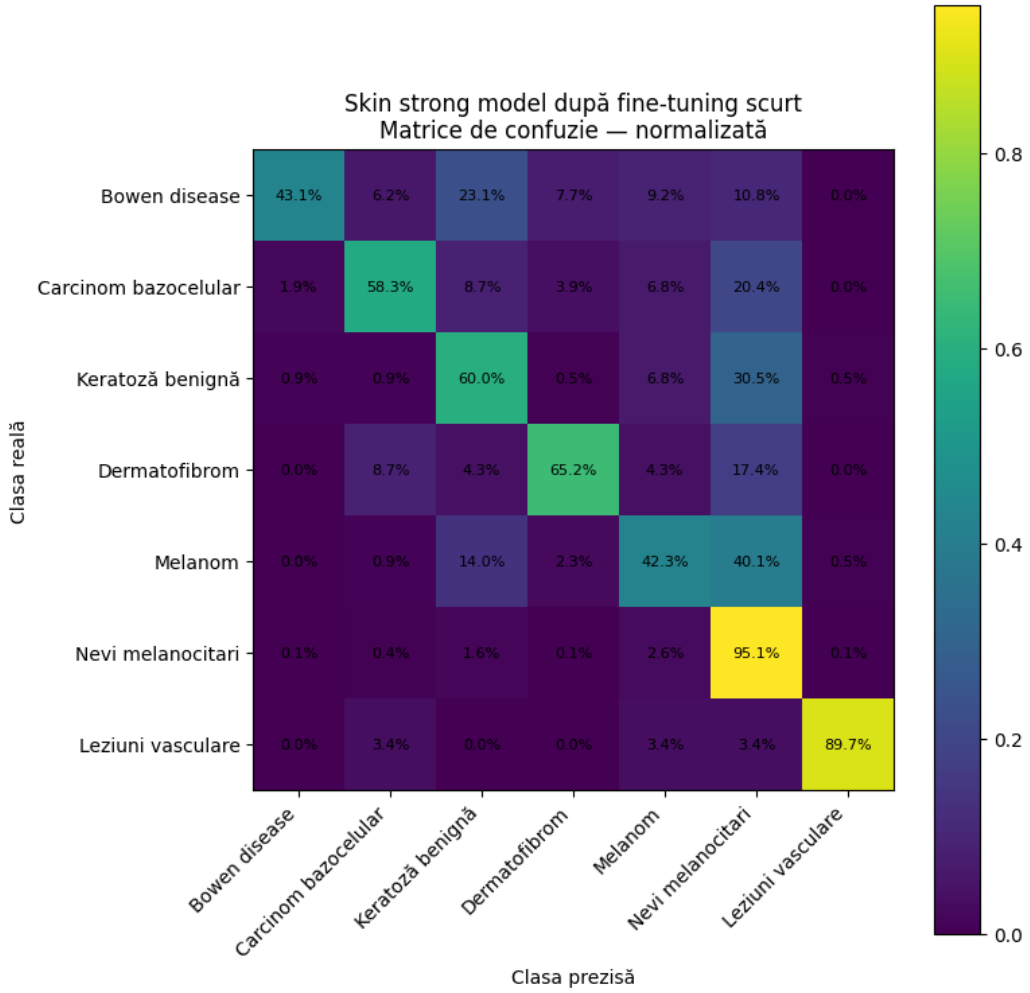
În anexă sunt puse variantele normalizate procentual ale matricilor incluse în raport. Acestea ajută la interpretarea performanței pe clase, mai ales în contextul dezechilibrului de date.



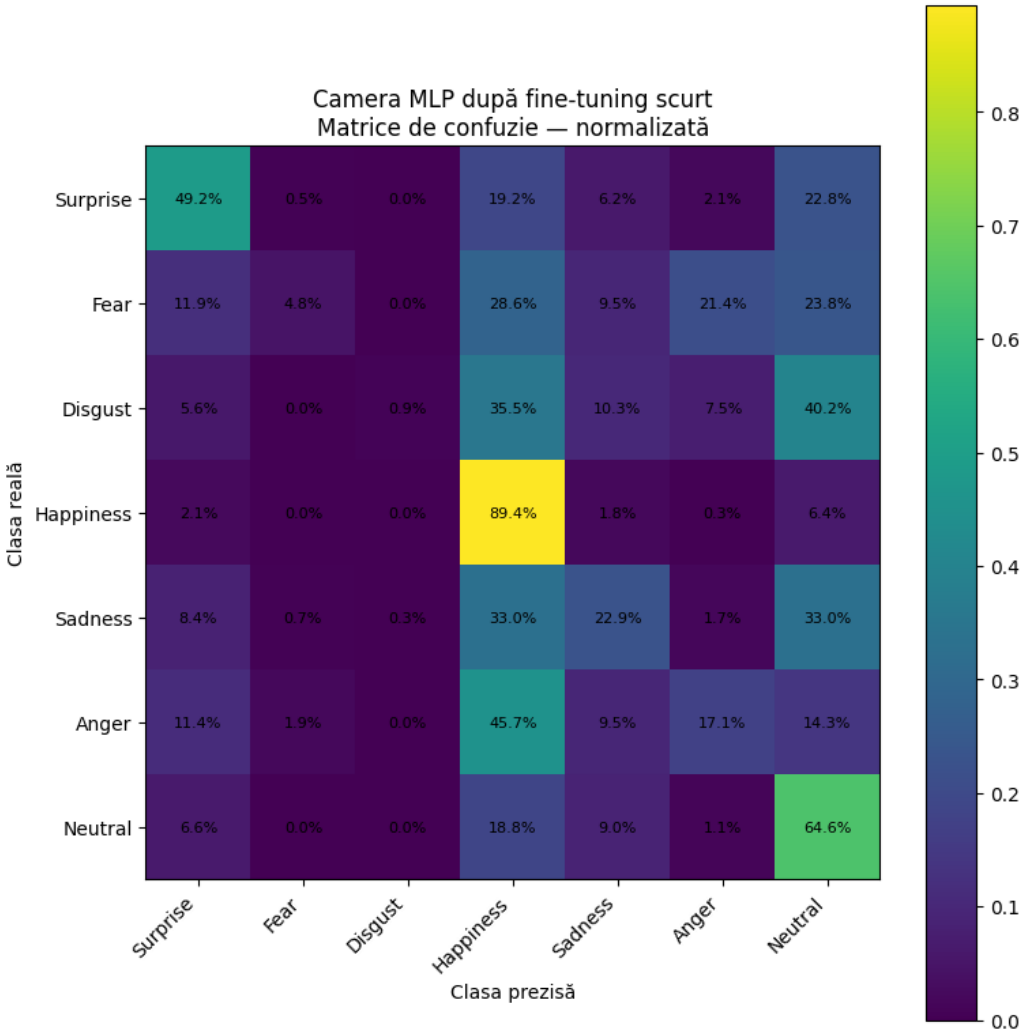
Anexa A1. Skin MLP - matrice normalizată.



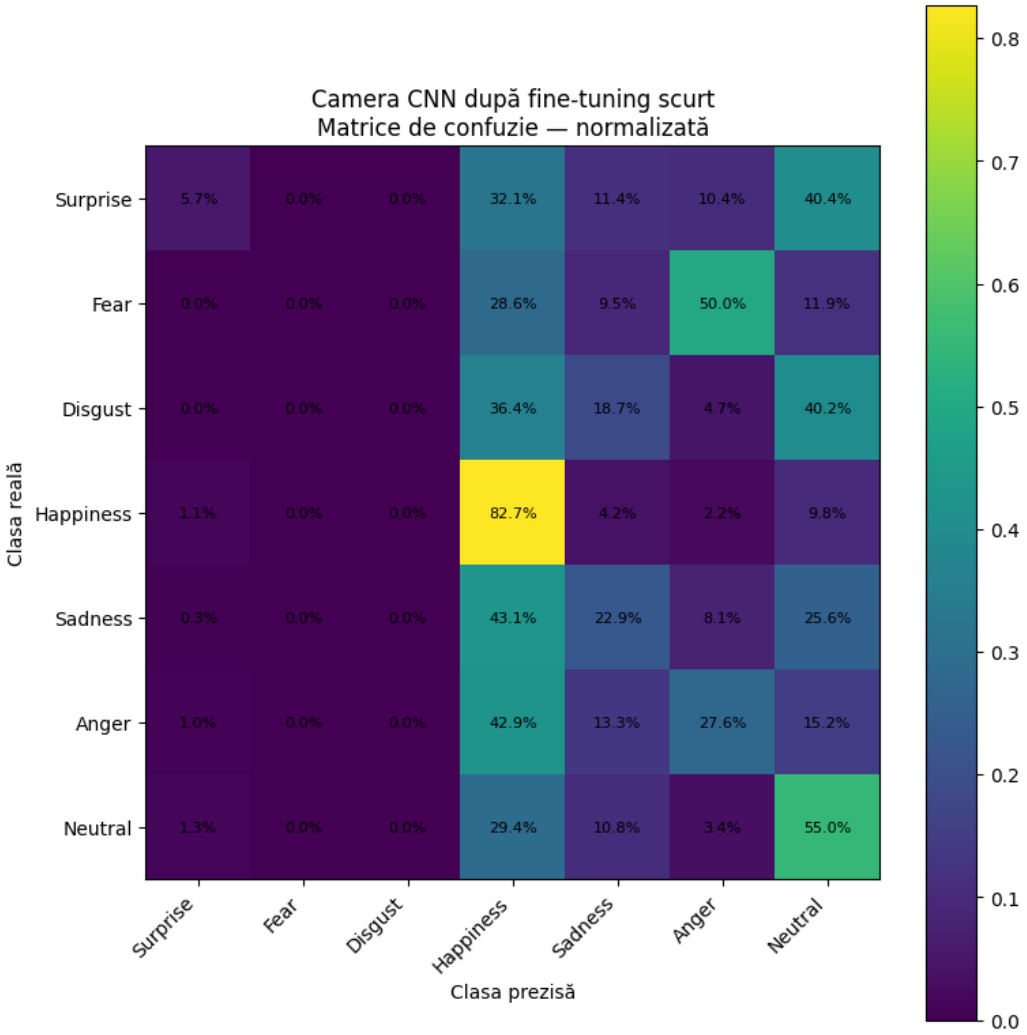
Anexa A2. Skin CNN - matrice normalizată.



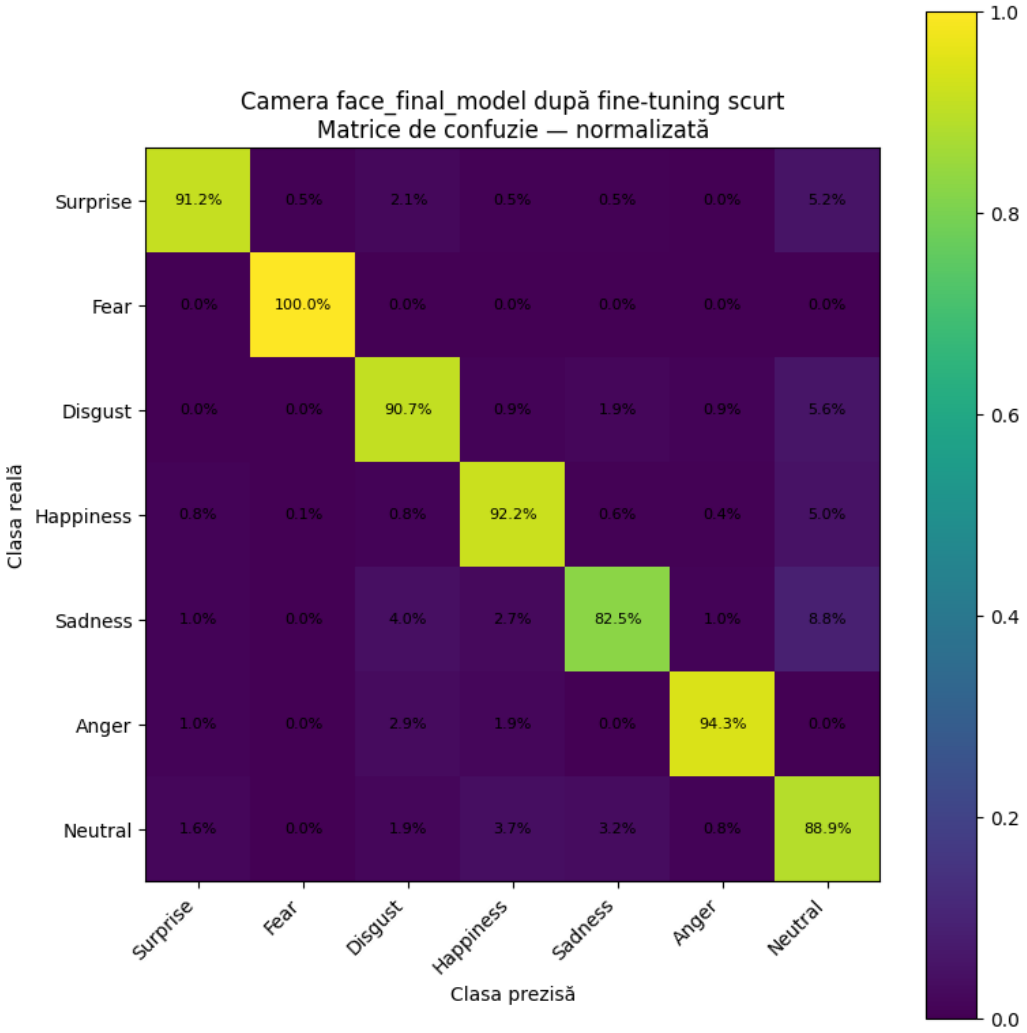
Anexa A3. Strong skin model - matrice normalizată.



Anexa A4. Camera MLP - matrice normalizată.



Anexa A5. Camera CNN - matrice normalizată.



Anexa A6. Camera face_final_model - matrice normalizată.